

Loess regrese a mnohonásobná regrese


Sergii Babichev

Univerzita Jana Evangelisty Purkyně v Ústí nad Labem

sergii.babichev@ujep.cz

Loess regrese


Loess (nebo LOWESS, z anglického "Locally Weighted Scatterplot Smoothing") je neparametrická regresní technika, která kombinuje několik regresních modelů v meta-modelu založeném na metodě k-nejbližších sousedů. Na rozdíl od lineární nebo logistické regrese, které modelují vztah jedním rovnicí, Loess aplikuje několik regresí v lokálních podmnožinách dat. Tento přístup umožňuje Loess modelovat složitější, nelineární vztahy, které se mohou lišit v různých rozsazích dat.



Klíčové charakteristiky regrese Loess:


- **Lokální regrese:** Loess modeluje jednoduché modely na lokálních podmnožinách dat, což je efektivní pro modelování složitých, nelineárních vztahů.
- **Vážené nejmenší čtverce:** V každé lokální podmnožině Loess používá vážené nejmenší čtverce, přičemž větší váhu přiřazuje bodům nejbližším k cílovému bodu, pro který je model stavěn.
- **Parametr vyhlazování (šířka pásma):** Stupeň vyhlazování je řízen parametrem, často nazývaným šířka pásma nebo rozpětí, který určuje, kolik dat je použito pro vytvoření každého lokálního modelu. Větší šířka pásma zahrnuje více bodů a vede k hladší křivce.
- **Flexibilita:** Loess může zachytit různé druhy struktur v datech bez předpokladu konkrétní globální formy (jako je linearita) pro vztah mezi proměnnými.
- **Výpočetní náročnost:** Vyžaduje více výpočetního výkonu než jednoduchá lineární regrese, zejména pro velké datové sady, protože zahrnuje vytváření mnoha malých modelů.
- **Robustnost:** Pro lepší robustnost vůči outlierům je možné použít Loess s robustní váhovou funkcí, která zmenšuje váhy pro odlehlé hodnoty.

Loess regrese: Local regrese




Loess regrese: Loess curve

Loess Regression: Aggregation of Local Models



Loess regrese: Loess prediction

Loess Regression: Prediction on Test Data



Interpretace:

- **Identifikace trendů:** Loess regrese se primárně používá pro vizualizaci trendu v datech.
- **Bez koeficientů:** Na rozdíl od lineární regrese Loess nevýsledkuje v jednoduché rovnici nebo koeficientech pro prediktory. Výstupem je hladká křivka, která reprezentuje vztah.

Aplikace:

- **Vizualizace dat:** Často se používá v explorativní analýze dat k vizualizaci trendu v datovém souboru.
- **Nelineární vztahy:** Užitečné, pokud je vztah mezi proměnnými známý jako nelineární, nebo když chcete prozkoumat povahu vztahu bez předpokladu linearity.
- **Ekonometrie a epidemiologie:** Loess se široce používá v různých vědeckých oborech, včetně ekonometrie, epidemiologie a sociálních věd, kde je třeba analyzovat složité, nelineární vztahy mezi proměnnými.

Omezení:

- **Subjektivita:** Volba šířky pásma/vyhlažovacího parametru může být do jisté míry subjektivní a výrazně ovlivňuje výsledný fit.
- **Přetrénování:** Existuje riziko přetrénování, pokud je šířka pásma příliš malá, což vede k modelu, který je příliš úzce vázán na šum v datech.
- **Extrapolace:** Loess není vhodný pro extrapolaci mimo rozsah dat.
- **Vícedimenzionální data:** Zatímco Loess funguje dobře pro univariátní a bivariátní data, jeho aplikace se stává složitější a výpočetně náročnější pro vyšší dimenze dat.
- **Vysoká složitost:** Pro velké soubory dat může být Loess výpočetně náročný, což omezuje jeho použití v reálných časech.

Mnohonásobná regresní analýza je statistická metoda, která umožňuje analyzovat vztah mezi jednou závislou proměnnou a více nezávislými proměnnými. Tato technika je široce používána v různých oblastech, včetně ekonomie, medicíny a sociálních věd, k odhalování potenciálních příčinných vztahů mezi proměnnými.

Základní pojmy:

- **Závislá proměnná (Y):** Proměnná, kterou chceme vysvětlit nebo předpovědět.
- **Nezávislé proměnné (X_i):** Proměnné, které používáme k předpovídání nebo vysvětlení závislé proměnné.
- **Koeficienty (β_i):** Reprezentují míru změny závislé proměnné při změně příslušné nezávislé proměnné o jednotku.
- **Chybový člen (ϵ):** Reprezentuje část závislé proměnné, kterou nelze vysvětlit pomocí modelu.

Matematický model: Model mnohonásobné regrese můžeme matematicky vyjádřit jako:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_n X_n + \epsilon \quad (1)$$

Tento model nám říká, že závislá proměnná Y je lineární funkcí nezávislých proměnných $X_1, X_2, \dots, X_n$, přičemž β_0 je y-intercept (bod, kde regresní přímka protíná y-ovou osu), $\beta_1, \beta_2, \dots, \beta_n$ jsou sklonové koeficienty jednotlivých nezávislých proměnných, a ϵ je chybový termín.

Předpoklady mnohonásobné regrese: Pro validní výsledky mnohonásobné regresní analýzy musí být splněny následující předpoklady:

1. Lineární vztah mezi závislými a nezávislými proměnnými.
2. Nezávislost reziduí (chybových členů).
3. Homoskedasticita reziduí (konstantní rozptyl chybových členů).
4. Normální rozdělení reziduí.
5. Žádná nebo minimální multikolinearita mezi nezávislými proměnnými.

Koeficient mnohonásobné korelace – interpretace

Definice:

Koeficient mnohonásobné korelace $\rho_{Y.X}$ je maximální možná korelace mezi náhodnou veličinou Y a libovolnou lineární kombinací vektoru $X = (X_1, \dots, X_p)^\top$:

$$\rho_{Y.X} = \max_{a \neq 0} \text{cor}(Y, a^\top X) \quad (2)$$

Význam:

- $\rho_{Y.X} \in [0, 1]$
- $\rho_{Y.X} = 0$ – žádná lineární závislost
- $\rho_{Y.X} = 1$ – dokonalá lineární závislost

Nejčastěji používáme druhou mocninu:

$$\rho_{Y.X}^2 \quad (3)$$

která vyjadřuje podíl vysvětlené variability Y .

Matematický tvar koeficientu

Platí vztah:

$$\rho_{Y.X}^2 = \text{cor}(Y, X) \text{cor}(X)^{-1} \text{cor}(X, Y) \quad (4)$$

kde:

- $\text{cor}(Y, X)$ – vektor korelací $(\rho_{Y,X_1}, \dots, \rho_{Y,X_p})$
- $\text{cor}(X)$ – korelační matice mezi $X_1, \dots, X_p$
- $\text{cor}(X, Y) = \text{cor}(Y, X)^\top$

Rozměry matic:

$$(1 \times p) (p \times p) (p \times 1) = (1 \times 1)$$

Výsledkem je skalární hodnota.

Číselný příklad (2 prediktory)

Nechť platí:

$$\text{cor}(Y, X_1) = 0.80, \quad \text{cor}(Y, X_2) = 0.60, \quad \text{cor}(X_1, X_2) = 0.50$$

Korelační matice:

$$\text{cor}(Y, X) = \begin{bmatrix} 0.80 & 0.60 \end{bmatrix}$$

$$\text{cor}(X) = \begin{bmatrix} 1 & 0.50 \\ 0.50 & 1 \end{bmatrix}$$

Nejprve vypočteme inverzi matice $\text{cor}(X)$.

$$\text{cor}(X)^{-1} = \frac{1}{1 - 0.5^2} \begin{bmatrix} 1 & -0.50 \\ -0.50 & 1 \end{bmatrix} = \frac{1}{0.75} \begin{bmatrix} 1 & -0.50 \\ -0.50 & 1 \end{bmatrix}$$

Výpočet inverze a mezivýsledek

Následně:

$$\text{cor}(X)^{-1} \begin{bmatrix} 0.80 \\ 0.60 \end{bmatrix} = \begin{bmatrix} 0.6667 \\ 0.2667 \end{bmatrix}$$

$$\rho_{Y.X}^2 = \begin{bmatrix} 0.80 & 0.60 \end{bmatrix} \begin{bmatrix} 0.6667 \\ 0.2667 \end{bmatrix}$$

$$\rho_{Y.X}^2 = 0.6933$$

$$\rho_{Y.X} = \sqrt{0.6933} \approx 0.833$$

Interpretace:

Lineární kombinace X_1, X_2 vysvětluje přibližně

69%

variability veličiny Y .

V modelu vícenásobné lineární regrese:

$$Y = \beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p + \varepsilon \quad (5)$$

platí:

$$R^2 = r_{Y.X}^2 \quad (6)$$

Závěr:

Koeficient mnohonásobné korelace je:

- matematickým základem koeficientu determinace,
- mírou lineární vysvětlitelnosti proměnné Y pomocí X ,
- citlivý na multikolinearitu mezi prediktory.

Test významnosti celého modelu

Uvažujme model:

$$Y = \beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p + \varepsilon$$

Nulová hypotéza:

$$H_0 : \beta_1 = \beta_2 = \cdots = \beta_p = 0$$

Alternativní hypotéza:

$$H_1 : \exists j \text{ takové, že } \beta_j \neq 0$$

Testové kritérium:

$$F = \frac{SR/p}{SE/(n-p-1)}$$

kde:

- SR – regresní součet čtverců
- SE – reziduální součet čtverců

Celková variabilita:

$$ST = SR + SE$$

kde:

- $ST = \sum (Y_i - \bar{Y})^2$ – celkový součet čtverců
- $SR = \sum (\hat{Y}_i - \bar{Y})^2$ – vysvětlená variabilita
- $SE = \sum (Y_i - \hat{Y}_i)^2$ – nevysvětlená variabilita

Koeficient determinace:

$$R^2 = \frac{SR}{ST}$$

Vztah mezi F-testem a R^2

Testové kritérium lze vyjádřit pomocí R^2 :

$$F = \frac{R^2/p}{(1 - R^2)/(n - p - 1)}$$

Interpretace:

- Čím větší R^2 , tím větší hodnota F
- Pokud $F > F_{1-\alpha}(p, n - p - 1)$, zamítáme H_0

F-test je tedy testem významnosti koeficientu determinace.

Dílčí t-testy regresních koeficientů

Pro každý koeficient β_j testujeme:

$$H_0 : \beta_j = 0$$

Testové kritérium:

$$t_j = \frac{\hat{\beta}_j}{s(\hat{\beta}_j)}$$

kde $s(\hat{\beta}_j)$ je směrodatná chyba odhadu.

Platí:

$$t_j \sim t(n - p - 1)$$

Pokud $|t_j| > t_{1-\alpha/2}(n - p - 1)$, koeficient je statisticky významný.

Parciální význam proměnné

Parciální index determinace:

$$R_{partial}^2 = \frac{\Delta SR}{SE_{reduced}}$$

Vyjadřuje „čistý“ příspěvek proměnné po odečtení vlivu ostatních proměnných.

Platí vztah:

$$F_j = t_j^2$$

Test významnosti jednotlivé proměnné je ekvivalentní parciálnímu F-testu.

Adjustovaný koeficient determinace

Pro penalizaci počtu proměnných používáme:

$$R_{adj}^2 = 1 - \frac{SE/(n - p - 1)}{ST/(n - 1)}$$

Vlastnosti:

- Může klesnout po přidání nevýznamné proměnné
- Vhodnější pro porovnávání modelů

Samotné R^2 vždy roste, R_{adj}^2 nikoli.

Posouzení vlivu jednotlivých nezávislých proměnných

Uvažujme odhadnutý model:

$$Y = \beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p + \varepsilon$$

Interpretace nestandardizovaného koeficientu: β_j udává změnu Y (v původních jednotkách) při jednotkové změně X_j , za předpokladu konstantních ostatních proměnných.

V praxi mají proměnné různé jednotky měření (např. roky, Kč, body, procenta).

Problém: Koeficienty β_j nelze přímo porovnávat, protože závisí na měřítku proměnných.

Řešení: Standardizujeme pouze nezávislé proměnné:

$$Z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_{X_j}}$$

a model odhadujeme ve tvaru:

$$Y = \alpha_0 + \alpha_1 Z_1 + \cdots + \alpha_p Z_p + \varepsilon$$

Parciální korelační koeficient v regresi

Uvažujme model:

$$Y_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip} + \varepsilon_i$$

Parciální korelační koeficient

$$r_{Y, X_j \cdot X_{-j}}$$

měří korelaci mezi Y a X_j po odstranění vlivu ostatních proměnných.

Vyjadřuje tedy „čistý“ lineární vztah mezi Y a X_j .

Druhá mocnina parciální korelace:

$$R_{partial,j}^2 = (r_{Y,X_j \cdot X_{-j}})^2$$

vyjadřuje podíl variability Y , který vysvětluje proměnná X_j nad rámec již zařazených proměnných.

Platí:

$$R_{partial,j}^2 = \frac{\Delta SR}{SE_{reduced}}$$

kde ΔSR je přírůstek regresního součtu čtverců po přidání X_j do modelu.

Vztah k testování významnosti

Testujeme hypotézu:

$$H_0 : \beta_j = 0$$

Platí vztah:

$$t_j^2 = F_j$$

a zároveň

$$R_{\text{partial},j}^2 = \frac{t_j^2}{t_j^2 + (n - p - 1)}$$

Parciální korelace, přírůstek SR a t-test jsou ekvivalentní způsoby hodnocení významnosti proměnné.

Ekvivalence t - a F -testu (jedna proměnná)

Testujeme hypotézu:

$$H_0 : \beta_j = 0$$

t -test:

$$t_j = \frac{\hat{\beta}_j}{s(\hat{\beta}_j)}, \quad t_j \sim t(n - p - 1)$$

Kritérium významnosti:

$$|t_j| > t_{1-\alpha/2}(n - p - 1)$$

F -test:

$$F_j = t_j^2, \quad F_j \sim F(1, n - p - 1)$$

Kritérium významnosti:

$$F_j > F_{1-\alpha}(1, n - p - 1)$$

Platí:

$$t_{1-\alpha/2}^2(n - p - 1) = F_{1-\alpha}(1, n - p - 1)$$

Závěr: t -test a F -test jsou při testování jedné proměnné ekvivalentní.

Numerický příklad

Nechť:

$$n = 30, \quad p = 3, \quad \alpha = 0.05$$

Stupně volnosti:

$$n - p - 1 = 26$$

Kritické hodnoty:

$$t_{0.975}(26) \approx 2.056$$

$$F_{0.95}(1, 26) \approx 4.23$$

Ověření ekvivalence:

$$2.056^2 \approx 4.23$$

Krok 1: Výběr prvního regresoru

- Vypočítáme párové korelační koeficienty mezi Y a $x_1, \dots, x_p$.
- Vybereme proměnnou x_i s největší absolutní hodnotou korelace.

Krok 2: Testování prvního modelu

Sestavíme model:

$$Y = \beta_0 + \beta_1 x_i + \varepsilon$$

Testové kritérium:

$$F = \frac{SR/1}{SE/(n-2)} \sim F(1, n-2)$$

Pokud:

$$F > F_{1-\alpha}(1, n-2),$$

zařadíme x_i do modelu.

Forward Selection – další kroky

Nechť je v modelu aktuálně k regresorů.

Krok 3: Výběr dalšího regresoru

- Vypočítáme parciální korelační koeficienty mezi Y a nezahrnutými proměnnými, očištěné o vliv již zařazených k regresorů.
- Vybereme proměnnou x_j s největší absolutní hodnotou parciální korelace.

Krok 4: Test přírůstku modelu

Porovnáme redukováný model (s k proměnnými) a plný model (s $k + 1$ proměnnými).

$$F = \frac{\Delta SR/1}{SE_{full}/(n - k - 1)} \sim F(1, n - k - 1)$$

Pokud:

$$F > F_{1-\alpha}(1, n - k - 1),$$

zařadíme proměnnou x_j do modelu.

Kriterium zastavení: Algoritmus končí, pokud žádná další proměnná nesplní test významnosti.

Mnohonásobná regrese: Příklad

Šest studentů gymnázia absolvovalo čtyři testy, které měří následující veličiny:

- X_1 - přírodovědné vědomosti,
- X_2 – literární vědomosti,
- X_3 – schopnost koncentrace,
- X_4 – logické myšlení. Testy se hodnotí na škále od 1 do 10 (1 = špatný výsledek, 10 = výborný výsledek).

student	X_1	X_2	X_3	X_4
1	7	9	10	8
2	9	8	8	10
3	4	3	1	2
4	2	3	2	2
5	3	1	2	4
6	1	1	1	4

Zajímá nás, kolik bodů můžeme očekávat v testu koncentračních schopností studenta, jestliže známe výsledky testů pro literární schopnosti, přírodovědné schopnosti a logické myšlení.

Příklad: data a volba proměnných

Máme $n = 6$ studentů a čtyři testy:

- X_1 – přírodovědné vědomosti,
- X_2 – literární vědomosti,
- X_3 – schopnost koncentrace,
- X_4 – logické myšlení.

Cíl: odhadnout očekávanou hodnotu X_3 (koncentrace) na základě X_1, X_2, X_4 .

$$Y = X_3, \quad X = (X_1, X_2, X_4)$$

Vstupní data: tabulka hodnot $(x_{i1}, x_{i2}, x_{i3}, x_{i4})$ pro $i = 1, \dots, 6$.

Regresní model a maticový zápis

Uvažujme model:

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \beta_3 X_{i4} + \varepsilon_i, \quad i = 1, \dots, n$$

Maticově:

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$$

kde:

$$\mathbf{y} = \begin{bmatrix} Y_1 \\ \vdots \\ Y_n \end{bmatrix}, \quad \mathbf{X} = \begin{bmatrix} 1 & X_{11} & X_{12} & X_{14} \\ \vdots & \vdots & \vdots & \vdots \\ 1 & X_{n1} & X_{n2} & X_{n4} \end{bmatrix}, \quad \boldsymbol{\beta} = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \beta_3 \end{bmatrix}$$

OLS odhad koeficientů (krok za krokem)

Krok 1: definujeme rezidua

$$\mathbf{e} = \mathbf{y} - \mathbf{X}\boldsymbol{\beta}$$

Krok 2: minimalizujeme součet čtverců reziduí

$$S(\boldsymbol{\beta}) = \mathbf{e}^\top \mathbf{e} = (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})^\top (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})$$

Krok 3: OLS řešení (normální rovnice)

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$$

Výstup: odhadnuté koeficienty $\hat{\beta}_0, \hat{\beta}_1, \hat{\beta}_2, \hat{\beta}_3$.

Predikce koncentrace pro studenta

Pro studenta s hodnotami (x_1, x_2, x_4) je predikce:

$$\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \hat{\beta}_3 x_4$$

Postup:

- 1 Dosadíme hodnoty (x_1, x_2, x_4) daného studenta.
- 2 Použijeme odhady $\hat{\beta}_j$ vypočtené z trénovacích dat.
- 3 Získáme očekávaný počet bodů v testu koncentrace $\hat{Y}$.

Poznámka: predikce je smysluplná pouze v rozsahu hodnot, které se vyskytují v datech (škála 1–10).

Kvalita modelu: koeficient determinace R^2

Po odhadu získáme predikce $\hat{Y}_i$ a rezidua $e_i = Y_i - \hat{Y}_i$.

$$ST = \sum_{i=1}^n (Y_i - \bar{Y})^2, \quad SE = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2, \quad SR = ST - SE$$

$$R^2 = \frac{SR}{ST} = 1 - \frac{SE}{ST}$$

Interpretace: R^2 udává, jaká část variability koncentrace Y je vysvětlena pomocí (X_1, X_2, X_4) .

Významnost koeficientů: t -test

Testujeme pro každý koeficient:

$$H_0 : \beta_j = 0$$

$$t_j = \frac{\hat{\beta}_j}{s(\hat{\beta}_j)}, \quad t_j \sim t(n - p - 1)$$

Kritérium (dvoustranný test):

$$|t_j| > t_{1-\alpha/2}(n - p - 1)$$

Závěr: pokud je koeficient významný, proměnná přispívá k vysvětlení Y nad rámec ostatních proměnných v modelu.